Pablo Alberto Duque Marín

Ingeniero de IA

Caldas, Colombia · remoto UTC−5 · pabdus3000@gmail.com
github.com/pabdus · linkedin.com/in/pablo-alberto-duque-marin

Portafolio: pabloduque.dev — casos de estudio, demos y laboratorios con datos reales
Disponible: freelance ahora · tiempo completo desde ene. 2027 · remoto

PERFIL

Llevo IA generativa a producción sobre AWS y mido con estadística si funciona. Diseño pipelines de documentos, RAG y agentes sobre Amazon Bedrock, con infraestructura en Terraform y pruebas automatizadas. Mido si funcionan con protocolos fijados antes de ver los datos, y publico también los resultados negativos.

EXPERIENCIA

Ingeniero de pipelines de IA e infraestructura (prácticas) jun. 2026 – actualidad
Softart · prácticas del máster: extracurriculares jun.–jul. y curriculares sep.–dic. 2026 *Remoto, Colombia*

- Responsable del backend y del pipeline de IA que lleva una reclamación del SOAT a un análisis listo para el abogado en una mediana de 28 s desde la asignación del caso (18 corridas de prueba), para un cliente del sector legal (Colombia).
- Orquestación por eventos con EventBridge, DynamoDB y SQS, con unos 57 recursos AWS en Terraform; numeración de casos sin huecos con 20 registros simultáneos (transacciones en DynamoDB); captcha, secretos de solo escritura y ningún dato personal en los logs.
- Rama de póliza con Amazon Textract y reglas deterministas, sin LLM a propósito: extraer no es interpretar. Rama médica con Claude por la API Converse de Bedrock y criterios versionados en Prompt Management; cada caso se resume en 10 hechos con su cita textual.
- Regla determinista que manda a revisión humana los casos cuya historia clínica no muestra un nexo claro con el accidente, conservando la respuesta original del modelo. Recomendé no mostrar la «confianza» del modelo: se agrupaba en 95, 85 y 0 sin escala definida.
- Pruebas de backend de 642 a 845 en 2 semanas y cobertura en código nuevo de 38 a 84 %, con historias clínicas sintéticas y veredicto esperado contra la función desplegada; arranque en frío de 867 a 545 ms.
- Agente contable (en construcción): arquitectura de un MVP de declaración de renta (F-110 y formato 2516) en el que el LLM nunca calcula cifras declarables: motor determinista en Python con aritmética Decimal, RAG solo para explicar y aprobación humana obligatoria. Diseño de 27 historias, 20 decisiones y 11 diagramas, e incremento 0 terminado, con 79 pruebas y CI en verde.

Ingeniero de infraestructura en la nube jul. – ago. 2026
Contrato independiente · SaaS fiscal (España) *Remoto*

- Migré a Frankfurt, por el RGPD, un asistente fiscal con RAG montado a mano en us-east-1: migración completa y verificada en Fráncfort en 9 días desde el diagnóstico (21–29 jul.); los defectos ligados a la región tras el corte se corrigieron el mismo día.
- Reorganicé la infraestructura en Terraform modular y multirregión (9 módulos, estado remoto aislado por región y entorno): 131 recursos y un plan sin diferencias frente a lo desplegado.
- Sustituí los dos modelos generativos al final de su vida por Claude Sonnet 4.5 y Haiku 4.5 en perfiles de inferencia europeos y migré el almacén vectorial de Aurora pgvector a S3 Vectors: datos y modelos dentro de la UE.

Analista de datos 2022 – 2026
Tubos y Perfiles de Occidente S.A.S. *Dosquebradas, Colombia*

- Construí procesos ETL en Python que integran datos operativos y comerciales de varias fuentes internas y externas.
- Reemplacé reportes manuales por scripts de Python programados y escribí el SQL de los análisis recurrentes que sustentan decisiones.

Fundador y gerente general 2019 – 2022
Narnia Producciones *Chile*

- Dirigí una productora de eventos: presupuestos, análisis de rentabilidad y negociación con proveedores.

Subteniente, comandante de unidad 2011 – 2018
Policía Nacional de Colombia *Colombia*

- Comandé unidades policiales operativas en distintas regiones de Colombia.

PROYECTOS

Los mismos 9 casos que en pabloduque.dev, en el mismo orden; los de clientes van sin nombres.

Del documento al dictamen: pipeline de IA para reclamaciones del SOAT ver caso · Código privado del cliente
Softart · cliente del sector legal · Colombia · 2026. **28 s** mediana de la asignación del caso al análisis listo para el abogado (18 corridas de prueba). Rama de póliza con Textract y reglas; rama médica con Claude en Bedrock y una regla determinista que lo vigila.

Migración de un asistente fiscal con RAG a Frankfurt por RGPD ver caso · Código privado del cliente
Contrato independiente · SaaS fiscal · España · jul.–ago. 2026. **9 días** del diagnóstico a la migración completa y verificada en Fráncfort. Terraform modular y multirregión, agentes Bedrock actualizados y paso de Aurora pgvector a S3 Vectors.

Cotejo: verificar la jurisprudencia citada antes de radicar ver caso · Repositorio privado
Proyecto propio · legal-tech · Colombia · 2026. **0 / 500** falsos rechazos en 500 sentencias reales. Revisa cada sentencia citada en un escrito contra fuentes oficiales: que exista, que no esté anulada y que la cita sea literal.

Facturas a Excel: reglas frente a un LLM local ver caso · github.com/pabdus/facturas-a-excel · demo en vivo · laboratorio
Proyecto propio · documentos · 2026. **240 / 240** campos exactos con LLM local y con Claude en Bedrock (reglas: 67 %). Facturas colombianas a JSON y Excel con validaciones contables, medidas campo por campo. Demo en vivo en AWS.

Detección de fallos en procesos industriales En curso ver caso · github.com/pabdus/tfm-fdd-core · laboratorio
TFM · Máster en IA · UNIR · 2026. **17 / 18** fallas idénticas a Yin (2012) · veredicto: no verificado. PCA con T^2 y SPE sobre Tennessee Eastman, verificación ciega contra la literatura y comparaciones con el protocolo fijado antes.

Evaluación crítica de CTGAN ver caso · github.com/pabdus/ctgan-adult-critical-evaluation
Investigación · UCI Adult · 2026. **62 %** valores imposibles con métricas favorables. Wasserstein y JSD daban buenos resultados mientras el 62 % de los valores generados era imposible.

SMOTE frente a CTGAN con desbalance extremo ver caso · github.com/pabdus/proyecto-02-obesidad-brfss
Investigación · BRFSS 2023 · 2026. **≤ 0,02** diferencia de F1-macro entre CTGAN y SMOTE: sin ganancia real. 3 modelos × 4 estrategias sobre 289.693 registros, medido con F1-macro.

Brechas urbano-rurales en Colombia ver caso · github.com/pabdus/proyecto-01-desigualdad-colombia
Investigación · censo DANE 2018 · 2026. **5,39×** odds de analfabetismo rural. Prueba Z, χ^2 y regresión logística sobre 15,3 M de registros del censo.

Agente contable: el modelo redacta, el motor calcula En construcción ver caso · Repositorio privado
Prácticas · Softart · 2026. **79** pruebas en verde del incremento 0 (motor monetario y NIT). MVP de declaración de renta (F-110 y formato 2516) a partir del balance de prueba, con cálculo determinista y aprobación humana.

FORMACIÓN

Máster Universitario en Inteligencia Artificial 2026 – feb. 2027
UNIR (España, en línea) · TFM en detección de fallos industriales *En curso · finaliza feb. 2027*

Maestría en Estadística Aplicada 2025 – actualidad
Universidad Cuauhtémoc (México, en línea) *En curso*

Pregrado en Ciencia de Datos 2023 – actualidad
Universidad Compensar (Colombia, en línea) · en curso, 4.º semestre *En curso*

Bootcamp de Data Science (800+ h) 2022 – 2023
Henry *Finalizado*

Administración Policial y técnico en sistemas 2007 – 2011
Policía Nacional · IES-CINOC *Finalizado*

COMPETENCIAS

Nivel de uso real: producción, proyectos propios o formación.

Lenguajes: Python, SQL, HCL · Terraform *(producción)*; R *(formación)*
IA generativa: Amazon Bedrock, Claude Sonnet / Haiku 4.5, Prompt Management, Knowledge Bases · S3 Vectors *(producción)*; Ollama · transformers *(proyectos)*
Documentos: Amazon Textract *(producción)*; pypdf · rapidfuzz, JSON Schema *(proyectos)*
ML y aprendizaje profundo: scikit-learn, XGBoost, PyTorch · CTGAN *(proyectos)*; Keras · TensorFlow, spaCy *(formación)*
Estadística: SciPy *(proyectos)*; statsmodels, R survey *(formación)*
Datos: pandas · NumPy, DynamoDB, PostgreSQL · MySQL *(producción)*; Parquet *(proyectos)*
Nube AWS: Lambda, EventBridge · SQS · SES, S3 · CloudFront · Route 53, Cognito · AppSync · Amplify *(producción)*
CI y calidad: GitHub Actions, pytest · mutación, SonarCloud *(producción)*
Observabilidad: CloudWatch Logs, CloudTrail *(producción)*
Evaluación de modelos: F1-macro · AUC, TSTR · DCR · MIA, Wilcoxon · Holm · TOST *(proyectos)*

IDIOMAS

Español nativo · inglés técnico (B1–B2): leo y escribo documentación